

Identificación de subgrupos clínicos de COVID-19 mediante expresión génica

**Integrantes: Rivera Morales David, Lopez Bernal Yeimi Lizet, Hidalgo Carrillo Amir
Gilberto, Badager Estrada Aaron Omar**

Conjunto de datos: GSE157103, RNA-seq de leucocitos de sangre completa

Genómica Computacional - 11 de junio de 2026

Introducción


COVID-19 severo no es un estado biológico único: combina respuesta inmune, inflamación, daño vascular y heterogeneidad clínica.

Esa diferencia clínica puede reflejar cambios moleculares en sangre, sobre todo en genes relacionados con inflamación y respuesta inmune.

Muestras totales: 126; COVID-19: 100;
controles: 26.

La etiqueta clínica principal para evaluar los grupos fue UCI/no UCI.

Introducción



Datos verificados

Genes retenidos después de filtrado: 11924.


Genes variables usados para PCA y agrupamiento: 3000.

Transformación principal: $\log_2(\text{TPM} + 1)$, escalada por gen.

GEO/NCBI confirma GSE157103 como serie pública de Homo sapiens con expresión por secuenciación de alto rendimiento.

Los archivos locales de conteos y TPM contienen 126 muestras alineadas.

Datos verificados



Pipeline

Filtrar genes reduce ruido de genes casi apagados.

$\log_2(\text{TPM} + 1)$ comprime valores extremos y ayuda a comparar genes.

PCA resume miles de genes antes de agrupar.

UCI/no UCI se usa después, solo para evaluar concordancia.

La semilla computacional del pipeline es 42.

Objetivo


Evaluar si un pipeline no supervisado de expresión génica identifica grupos moleculares parcialmente concordantes con UCI/no UCI.

Hipótesis: la sangre contiene una señal transcriptómica de severidad, aunque no una separación clínica perfecta.

Se probaron k-means, agrupamiento jerárquico y DBSCAN.

- k-means: 5 corridas con distintos k.
- Jerárquico: 15 corridas con Ward, average y complete.
- DBSCAN: 44 corridas con búsqueda k-NN de eps y min_samples.
- Mejor DBSCAN: ARI=0.060, ruido=0.57.
- DBSCAN sí está en la tabla final, pero no fue el método con mayor concordancia clínica.

Métodos Comparados



Mejor Resultado

Mejor método: agrupamiento jerárquico (ward, k=2).

ARI: 0.263.


Silueta: 0.176.

NMI: 0.207.

La recuperación de UCI/no UCI fue parcial, no una clasificación perfecta.

ARI mide concordancia con UCI/no UCI; silueta mide separación interna.


Grupos 0 y 1 comparados



Grupos 0 y 1 comparados

Grupo 0 concentra 40/54 pacientes UCI; grupo 1 concentra 36/46 pacientes no UCI. La señal existe, pero hay mezcla clínica relevante.

Grupo	UCI	No UCI
0	40	14
1	10	36



Genes marcadores


Grupo 0: IL1R2, C3orf86, UPP1, OLAH, GRB10, ROPN1L, GMFG, LRG1.

Grupo 1: CD4, TMEM109, AARS2, ST3GAL5, TP53, CHST14, DCP1B, PATZ1.

Grupo 0 muestra genes compatibles con respuesta innata/inflamatoria.

Grupo 1 muestra un perfil más relacionado con células T y regulación celular.

Genes marcadores



Enriquecimiento funcional

Grupo 0: degranulación de neutrófilos; respuesta a estímulos; respuesta inflamatoria; respuesta de defensa.

Grupo 1: diferenciación de células Th17; diferenciación de células Th1 y Th2; metabolismo de RNA no codificante; ensamblaje de snRNP.

La señal más clara se relaciona con inflamación, respuesta de defensa y sistema inmune innato.


La interpretación es biológica y exploratoria, no un diagnóstico individual.

Limitaciones

Sangre completa mezcla composición celular y activación transcripcional.

Los marcadores se calcularon de forma exploratoria sobre $\log_2(\text{TPM} + 1)$.

g:Profiler depende de bases de datos externas que pueden actualizarse.



Conclusiones

Los transcriptomas sanguíneos contienen señal asociada a severidad clínica.

El mejor agrupamiento recupera parcialmente UCI/no UCI: ARI=0.263 y exactitud binaria aproximada de 0.76.

La interpretación biológica es más fuerte que una clasificación binaria perfecta: inflamación, respuesta innata y fenotipos inmunes.

Trabajo futuro: validar con DESeq2/limma y ajustar por edad, sexo y comorbilidades.

Bibliografía

Overmyer et al., Cell Systems, 2021.

GEO/NCBI, GSE157103, 2020.

Pedregosa et al., Journal of Machine Learning Research, 2011.

McInnes et al., Journal of Open Source Software, 2018.

Raudvere et al., Nucleic Acids Research, 2019.

Benjamini y Hochberg, JRSS-B, 1995.