

Identificación de subgrupos clínicos de COVID-19 mediante expresión génica

Rivera Morales David
Lopez Bernal Yeimi Lizet
Hidalgo Carrillo Amir Gilberto
Badager Estrada Aaron Omar

Genómica Computacional – Semestre 2026-II
GSE157103, GEO/NCBI

Resumen

Este proyecto analiza GSE157103 para revisar si la expresión génica en sangre permite formar grupos parecidos a UCI/no UCI en pacientes con COVID-19. Se usaron matrices procesadas de conteos esperados y TPM, se filtraron genes con baja señal y se trabajó con $\log_2(TPM + 1)$. Después se compararon k-means, agrupamiento jerárquico y DBSCAN. El mejor resultado fue agrupamiento jerárquico con ward, $k=2$, con $ARI=0.263$, $NMI=0.207$, silueta= 0.176 y exactitud binaria aproximada de 0.76 . La señal no es perfecta, pero sí es consistente: un grupo concentra más pacientes UCI y el otro más pacientes no UCI.

1 Introducción

COVID-19 no se presenta igual en todos los pacientes. Algunos cursan la enfermedad con síntomas moderados y otros requieren cuidados intensivos. Esa diferencia clínica puede reflejar cambios moleculares en sangre, sobre todo en genes relacionados con inflamación y respuesta inmune. La pregunta de este proyecto fue directa: si no se le dan al algoritmo las etiquetas UCI/no UCI, ¿los perfiles de expresión forman grupos parecidos a esas categorías?

2 Datos y metodología

Se usaron tres archivos de GSE157103: conteos esperados, TPM y metadatos de GEO. Después de alinear expresión y metadatos quedaron 126 muestras: 100 COVID-19 y 26 controles no COVID-19. Dentro de las muestras COVID-19 hay 50 pacientes UCI y 50 no UCI. La comparación principal se hizo solo con pacientes COVID-19.

Se retuvieron genes con TPM al menos 1 y conteos esperados al menos 10 en un mínimo de 5 muestras COVID-19 o 10% de las muestras COVID-19. Después del filtrado quedaron 11924 genes. La expresión se transformó como $\log_2(TPM + 1)$ y se seleccionaron los 3000 genes de mayor varianza.

Se aplicaron PCA y UMAP para visualización. Para agrupamiento se compararon k-means, agrupamiento jerárquico y DBSCAN. La concordancia con UCI/no UCI se evaluó con ARI , NMI , silueta y exactitud binaria cuando el método produjo dos grupos.

Procesamiento aplicado

1. Se filtraron genes con baja expresión.
2. Se aplicó la transformación $\log_2(TPM + 1)$.
3. Se seleccionaron los 3000 genes más variables.
4. Se aplicó PCA y UMAP.
5. Se probaron k-means, agrupamiento jerárquico y DBSCAN.
6. UCI/no UCI se usó solo para evaluar los grupos, no para construirlos.

3 Resultados

El mejor método por ARI fue el agrupamiento jerárquico con ward, k=2. El resultado fue:

Métrica	Valor
ARI	0.263
NMI	0.207
Silueta	0.176
Exactitud binaria	0.76

Comparación por método

Método	Corridas	Mejor configuración	Grupos	ARI	Silueta	Ruido
DBSCAN	44	min_samples=3, eps=22.71	6	0.060	-0.055	0.57
jerárquico	15	ward, k=2	2	0.263	0.176	0.00
k-means	5	k=3	3	0.226	0.229	0.00

DBSCAN se evaluó en 44 combinaciones de parámetros. Su mejor ARI fue 0.060 con min_samples=3, eps=22.71 y fracción de ruido 0.57. Esto deja claro que DBSCAN sí se probó, pero no fue el método más útil para esta pregunta.

Tabla grupo vs. UCI

Grupo	UCI	No UCI
0	40	14
1	10	36

- **Grupo 0:** 40/54 UCI (74.1%) y 14/54 no UCI (25.9%).
- **Grupo 1:** 10/46 UCI (21.7%) y 36/46 no UCI (78.3%).

Observación: el grupo 0 concentra más pacientes UCI y el grupo 1 concentra más pacientes no UCI. La separación no es perfecta, pero sí hay una dirección clara.

Genes marcadores principales

- **Grupo 0:** IL1R2, C3orf86, UPP1, OLAH, GRB10, ROPN1L, GMFG, LRG1, FLOT1, RSPH14
- **Grupo 1:** CD4, TMEM109, AARS2, ST3GAL5, TP53, CHST14, DCP1B, PATZ1, EID2, RSAD1

Enriquecimiento funcional

- **Grupo 0:** degranulación de neutrófilos; respuesta a estímulos; respuesta inflamatoria; respuesta de defensa; sistema inmune innato
- **Grupo 1:** diferenciación de células Th17; diferenciación de células Th1 y Th2; metabolismo de RNA no codificante; ensamblaje de snRNP; infección por virus de leucemia de células T humanas tipo 1

Observación: el grupo 0 tiene una señal más inflamatoria. Genes como *IL1R2*, *UPP1*, *OLAH* y *LRG1* son compatibles con activación inmune innata y cambios mieloides. El grupo 1 incluye *CD4* y términos relacionados con células T, por lo que parece menos dominado por inflamación innata.

4 Figuras principales




Figure 1: Control de calidad por tipo de muestra y estado UCI.




Figure 2: PCA de muestras COVID-19 coloreado por estado UCI y grupo seleccionado.




Figure 3: Comparación de métodos por índice de Rand ajustado.




Figure 4: Mapa de calor de genes marcadores por grupo.

5 Discusión

El resultado apoya la hipótesis, pero con cuidado. Los transcriptomas sanguíneos sí contienen información relacionada con severidad, aunque no separan a todos los pacientes sin error. Esto tiene sentido porque UCI/no UCI es una etiqueta clínica práctica, no un estado molecular puro. La parte más fuerte del análisis es la coherencia entre el grupo con más pacientes UCI, los genes marcadores y los términos funcionales de inflamación/respuesta innata.

Limitaciones principales:

- Se usaron matrices procesadas de GEO, no lecturas crudas.
- No se ajustó por edad, sexo, ventilación mecánica ni comorbilidades.

- Los marcadores son exploratorios y no sustituyen DESeq2 o limma-voom.
- Sangre completa mezcla composición celular y activación transcripcional.
- g:Profiler depende de bases de datos externas que pueden cambiar.

6 Conclusión

El agrupamiento no supervisado recuperó una señal parcial de UCI/no UCI en GSE157103. El mejor resultado fue agrupamiento jerárquico con ward, $k=2$, $ARI=0.263$ y exactitud binaria aproximada de 0.76. El resultado no funciona como diagnóstico perfecto, pero sí muestra una señal biológica consistente: inflamación, respuesta innata y degranulación de neutrófilos aparecen en el grupo con mayor proporción de pacientes UCI.

Bibliografía

1. Overmyer, K. A. et al. (2021). Large-Scale Multi-omic Analysis of COVID-19 Severity. *Cell Systems*, 12(1), 23–40.e7.
2. NCBI GEO. GSE157103: Large-scale Multi-omic Analysis of COVID-19 Severity.
3. Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
4. McInnes, L. et al. (2018). UMAP: Uniform Manifold Approximation and Projection. *Journal of Open Source Software*, 3(29), 861.
5. Raudvere, U. et al. (2019). g:Profiler: a web server for functional enrichment analysis. *Nucleic Acids Research*, 47(W1), W191–W198.
6. Benjamini, Y. y Hochberg, Y. (1995). Controlling the False Discovery Rate. *Journal of the Royal Statistical Society: Series B*, 57(1), 289–300.